

Tecnológico de Monterrey

CAMPUS QUERÉTARO

MA2008B: Análisis numérico para la optimización no-lineal

Forecasting Industrial y Sistemas de Control para Hornos de Producción de Rines de Aluminio

Integrantes:

Felipe de Jesús Damián Rodríguez	A01707246
Facundo Bautista Barbera	A01066843
Gabriela Marissa Mosquera Orellana	A01666191
Pablo Alberto Ramos Roldán	A01707339
Yamil Nuñez Sosa	A01711821

Junio 2026

Contents

1	Introducción	2
2	Problemática Industrial	2
3	Impacto del Problema en la Fabricación de Rines de Aluminio	3
3.1	Propiedades termofísicas de la aleación	3
3.2	Defectos por Desviaciones térmicas	4
4	Modelado Matemático del Sistema de Control	5
4.1	Representación en espacio de estados	6
4.2	Diseño del controlador por localización arbitraria de polos	7
4.3	Incorporación de perturbaciones	9
4.4	Observador de estados	10
4.5	Implementación en Simulink	11
4.6	Desempeño del sistema	13
4.7	Cierre de la solución de control	14
5	Análisis Exploratorio de Datos	15
5.1	Evaluación del horno	22
5.2	Hallazgos principales	23
5.3	Disponibilidad de los datos	24
6	Selección y Justificación del Modelo de Deep Learning	24
6.1	Partición de datos	26
6.2	Requisitos que impone el EDA al modelo	26
6.3	Alternativas evaluadas y criterios de descarte	27
6.4	Decisiones de diseño concretas	27
7	Implementación del Modelo de Deep Learning	28
7.1	Entrenamiento	28
7.2	Resultados del autoencoder	28
7.3	Resultados del modelo de espacio de estados latente	29
8	Comparación entre el Modelo de Control y el Modelo de Deep Learning	30
9	Discusión de Resultados	34
10	Conclusiones	36

1 Introducción

El control térmico de los procesos metalúrgicos modernos constituye una de las variables más críticas para garantizar la integridad, precisión y viabilidad comercial de los componentes fundidos. En las industrias automotriz, aeroespacial y de ingeniería, el proceso de fundición a baja presión (Low Pressure Die Casting, LPDC) ofrece una precisión dimensional superior y reduce los defectos de fundición (Kalyani, 2026). Específicamente en la manufactura de rines de aleación ligera, componentes estructurales de aluminio y piezas industriales de *precision-engineered* dependen absolutamente de la estabilidad térmica del metal líquido suministrado a los hornos (Kalyani, 2026). Las variaciones no controladas en la temperatura del aluminio fundido alteran drásticamente la dinámica de solidificación, comprometiendo la calidad del producto final y disminuyendo la eficiencia general del ciclo de manufactura.

Los hornos de sostenimiento, normalmente alimentados por elementos de resistencia eléctrica o quemadores de gas, actúan como un amortiguador térmico e hidráulico crítico en la línea de producción ininterrumpida. A diferencia de los hornos fusores, cuya función primordial es el cambio de fase del lingote sólido; el horno de sostenimiento tiene como objetivo mantener la aleación en estado líquido a una temperatura constante y homogénea, típicamente en un rango entre 690°C y 720°C. Para que esto sea posible, el sistema debe compensar de manera continua y precisa la pérdidas de calor por conducción a través de las capas de material refractario, la convección en la interfaz metal-atmósfera y la radiación térmica extrema que ocurre al abrir las compuertas para el traslado de material. La complejidad inherente a estos sistemas térmicos se caracteriza por una inercia térmica bastante grande, fuertes no linealidades radiativas, pues el calor que emiten las resistencias hacia el metal no aumenta en línea recta, sino que cambia de forma drástica; y perturbaciones estocásticas operacionales. Estas características hacen que los controladores clásicos Proporcional-Integral-Derivativo (PID) estándar presenten limitaciones operativas drásticas, evidenciados por sobreimpulsos térmicos excesivos, tiempos de estabilización prolongados y fluctuaciones continuas que degradan la calidad metalúrgica.

Dentro de este análisis abordamos el modelado, caracterización y diseño de estrategias de control para un horno de sostenimiento utilizado en la inyección de aleaciones de aluminio. El enfoque central radica en la disección de la dinámica térmica del equipo desde dos paradigmas complementarios: el enfoque analítico basado en las leyes físicas de la termodinámica acoplado al control moderno mediante la representación en el espacio de estados, y el enfoque empírico fundamentado mediante arquitecturas de Deep Learning.

2 Problemática Industrial

La operación de los hornos de sostenimiento en la industria de la fundición se enfrenta a perturbaciones dinámicas excepcionalmente complejas debido a las exigencias del proceso continuo. El equipo de sostenimiento recibe aluminio previamente fundido y debe estabilizarlo térmicamente antes de que la inyección neumática tome lugar. En el proceso LPDC, se inyecta aire comprimido seco o gas inerte en el recipiente hermético del horno a presiones meticulosamente controladas, forzando al fluido a ascender a través de un tubo refractario hacia la cavidad del molde garantizando un llenado laminar libre de turbulencias. La problemática principal de control, radica en la naturaleza altamente variante y no lineal de la carga térmica. Cuando se transfiere aluminio líquido al horno de

sostenimiento, se introduce una masa térmica masiva a una temperatura que invariablemente difiere del setpoint del controlador local. Estas adiciones periódicas constituyen perturbaciones escalón masivas. Adicionalmente, el aislamiento térmico refractario del horno sufre una degradación estructural e infiltración de alúmina con el transcurso de las campañas de producción, modificando gradualmente las constantes de resistencia térmica del sistema y alterando la respuesta dinámica original de la planta. Pues, con el uso continuo, el aluminio líquido penetra los poros de los refractarios del horno. Como el aluminio reacciona químicamente con la sílice del material, esta nueva aliación que se forma conduce el calor mucho más rápido que el aislante original, provocando que el horno empiece a perder energía hacia el exterior. Al perder calor más rápido, la planta ya no responde de la misma manera a los controles que cuando estaba nueva.

La termodinámica del sistema agrava la dificultad del control. Las pérdidas de calor hacia el exterior no son proporcionales a la diferencia de temperaturas, sino que están regidas en gran medida por la ley de radiación de Stefan-Boltzmann tanto en la superficie del baño de metal fundido como en los elementos calefactores de carburo de silicio. Como consecuencia matemática, el sistema requiere variaciones de energía desproporcionadas para corregir desviaciones térmicas a altas temperaturas en comparación con estados térmicos inferiores. Un lazo de control PID simple opera bajo un esquema de retroalimentación puramente reactivo y no modela el comportamiento multivariable espacial de la discrepancia temporal entre la temperatura de las resistencias, la temperatura del cecrisol y la temperatura real del núcleo del baño de metal. La inercia térmica de cientos de kilogramos de aleación de aluminio es considerable; consecuentemente, cuando el sistema convencional detecta una caída de temperatura e incrementa drásticamente la potencia de las resistencias eléctricas, el extenso retardo en la transferencia de calor invariablemente provoca que el controlador sobrecompense. El calor acumulado en los elementos calefactores continúa fluyendo hacia el metal mucho después de que se haya alcanzado el setpoint, resultando en oscilaciones perjudiciales y sobrecalentamiento cíclicos.

3 Impacto del Problema en la Fabricación de Rines de Aluminio

Las oscilaciones y la inestabilidad en la temperatura de sostenimiento tienen un impacto directo, irreversible y económicamente cuantificable en la integridad estructural, la estética y la viabilidad de los rines de aleación ligera. La industria automotriz estandariza el uso de aleaciones hipoeutécticas de la familia Al-Si-Mg, siendo la aleación A356 (7% Silicio, 0.3% Magnesio) la mayor predominancia mundial para el proceso LPDC. Nos basaremos en esa aleación para el análisis. Un control térmico deficiente en la fase de sostenimiento desencadena una cascada de defectos de fundición que incrementan significativamente las tasas de rechazo, aumentan el requerimiento de inspecciones radiográficas y representan un desperdicio energético injustificable.

3.1 Propiedades termofísicas de la aleación

La aleación A356 a pesar de sus sobresaliente colabilidad, hermeticidad a la presión y excelente respuesta a tratamientos térmicos de solubilización y envejecimiento; presenta rangos críticos de transición de fase que deben de respetarse estrictamente. Su temperatura liquidus se sitúa en aproximadamente 615°C y su temperatura solidus en apróxi-

madamente 555°C, como existe una brecha este se denomina rango de congelación. Es en este espacio que la sustancia consiste en una mezcla de la fase sólida y líquida. Es también en esta zona donde ocurren los defectos, por razones principalmente: el gas hidrógeno que ya estaba disuelto en el aluminio líquido es expulsado hacia afuera cuando el metal se vuelve sólido, formando poros interdendríticos; la segunda, el metal se contrae al enfriarse y bloquea los canales impidiendo que fluya más aluminio para rellenar los vacíos. Estos defectos arruinan la calidad del rin y hace que se tengan que volver a fundir. Por último, el proceso LPDC exige que el metal ingrese a la matriz a un flujo suave para evitar atrapar aire o crear óxidos. Para lograrlo, el líquido debe de tener el espesor correcto, lo cual va a depender de la temperatura mantenida en el horno de sostenimiento.

3.2 Defectos por Desviaciones térmicas

Las anomalías en el sistema de control térmico inducen directamente tres categorías principales de defectos estructurales en los rines, los cuales comprometen la seguridad del vehículo (Zhang et al., 2005):

- Macro- or shrinking porosity.

Ocurre cuando la temperatura del horno de sostenimiento cae por debajo del umbral óptimo operativo. Al ingresar frío al molde, las fracciones sólidas del metal aumentan prematuramente aislando secciones de la pieza antes de que el ciclo de presurización pueda completarse. Como el aluminio A356 experimenta una contracción volumétrica severa al pasar de líquido a sólido. Si la temperatura inicial es deficiente, la red de dendritas de solidificación bloquea canales, impidiendo que el metal líquido presurizado desde el horno compense la contracción en las zonas afectadas, generando vacíos internos críticos (Zhang et al., 2005).

- Microporosity.

Es un defecto ligado al sobreimpulso térmico del sistema de control. La termodinámica de las aleaciones de aluminio dicta que la solubilidad del gas hidrógeno en el aluminio fundido se incrementa exponencialmente a medida que la temperatura se eleva por encima de los 720°C. Si el controlador genera picos de calentamiento incontrolados, el baño de metal absorberá la humedad del aire circundante o de los refractarios. Durante el enfriamiento posterior, cuando se solidifica, el aluminio ya no puede retener el gas. Expulsa el hidrógeno y se comienzan a formar porosidades, estas terminan destruyendo las propiedades de elongación de la aleación y provocan fugas de presión en las llantas. Pues, un rin con porosidades es más probable que se agriete o se quiebre al golpear un bache. Si, además, están se conectan unas con otras hasta la superficie, provocan fugas microscópicas que hacen que la llanta pierda aire con el tiempo (Zhang et al., 2005).

- Oxide films.

Estas se producen por la extrema reactividad química del aluminio fundido con el oxígeno. En el momento en que la superficie del aluminio líquido entra en contacto con el aire, acelera drásticamente la tasa de oxidación superficial, formando gruesas capas de óxido de aluminio. Estas películas generadas pueden llegar a ser arrastradas hacia la zona de succión e ingresarán al molde. Una vez formado el rin, este pliegue de óxido actúa como si fuera una grieta preexistente en la estructura interna de la

pieza. Esta falsa grieta destruye la integridad del metal y reduce drásticamente su resistencia a la fatiga.

4 Modelado Matemático del Sistema de Control

En esta sección se desarrolla el modelo matemático del horno de sostenimiento para diseñar un sistema de control moderno. El horno se modeló como un sistema térmico de primer orden con retardo, ya que su respuesta es lenta debido a la inercia térmica del aluminio fundido y del material refractario.

El modelo inicial se representó mediante la siguiente función de transferencia con retardo:

$$G(s) = \frac{K_p e^{-\theta s}}{\tau s + 1}$$

Donde K_p representa la ganancia térmica del horno, τ es la constante de tiempo dominante del sistema y θ representa el retardo asociado a la respuesta térmica del proceso.

Debido a que el término exponencial de retardo dificulta la representación directa en espacio de estados, se utilizó una aproximación de Padé de primer orden. Esta aproximación permite representar el retardo de transporte de un sistema lineal mediante una función racional, lo cual facilita su análisis y su posterior conversión a espacio de estados.

$$e^{-\theta s} \approx \frac{1 - \frac{\theta}{2}s}{1 + \frac{\theta}{2}s}$$

Sustituyendo esta aproximación en la función de transferencia original, se obtuvo:

$$G(s) = \frac{K_p (1 - \frac{\theta}{2}s)}{(\tau s + 1) (1 + \frac{\theta}{2}s)}$$

Después de expandir y normalizar el denominador, la función de transferencia queda en la forma:

$$G(s) = \frac{-\frac{K_p}{\tau}s + \frac{2K_p}{\tau\theta}}{s^2 + \frac{2\tau+\theta}{\tau\theta}s + \frac{2}{\tau\theta}}$$

Esta expresión fue la base utilizada en MATLAB, ya que permite sustituir directamente los valores de K_p , τ y θ para obtener la función de transferencia del horno.

Para el caso estudiado se utilizaron los siguientes parámetros:

$$K_p = 700, \quad \tau = 3600, \quad \theta = 300$$

Con estos valores se obtuvo la siguiente función de transferencias:

$$G(s) = \frac{-0.1944s + 0.001296}{s^2 + 0.006944s + 1.852 \times 10^{-6}}$$

Estos parámetros fueron seleccionados porque generan una dinámica lenta y progresiva, más consistente con un horno de sostenimiento industrial. En particular, el valor $\tau = 3600$ representa una constante de tiempo elevada, lo cual refleja que la temperatura del horno no cambia de manera instantánea, sino de forma gradual.

4.1 Representación en espacio de estados

A partir de la función de transferencia obtenida, el sistema se convirtió a una representación en espacio de estados. Esta forma permite describir la dinámica interna del horno mediante matrices y facilita el uso de herramientas de control moderno, como re-alimentación de estados, localización de polos y observadores.

El modelo se escribió mediante una ecuación de estado y una ecuación de salida. La ecuación de estado describe cómo evolucionan las variables internas del sistema, mientras que la ecuación de salida permite obtener la temperatura del horno a partir de dichas variables.

El modelo general se escribió como:

$$\dot{x}(t) = Ax(t) + Bu(t)$$

$$y(t) = Cx(t)$$

Donde $x(t)$ es el vector de estados, $u(t)$ es la entrada de control y $y(t)$ es la salida del sistema.

Para la función de transferencia obtenida, las matrices se formularon como:

$$A = \begin{bmatrix} 0 & 1 \\ -\frac{2}{\tau\theta} & -\frac{2\tau+\theta}{\tau\theta} \end{bmatrix}$$

$$B = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$C = \begin{bmatrix} \frac{2K_p}{\tau\theta} & -\frac{K_p}{\tau} \end{bmatrix}$$

Sustituyendo los valores $K_p = 700$, $\tau = 3600$ y $\theta = 300$, se obtuvo:

$$A = \begin{bmatrix} 0 & 1 \\ -1.852 \times 10^{-6} & -0.006944 \end{bmatrix}$$

$$B = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$C = \begin{bmatrix} 0.001296 & -0.1944 \end{bmatrix}$$

En esta representación, el primer estado se interpreta como la temperatura del horno y el segundo como la velocidad de cambio de la temperatura:

$$x(t) = \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix}$$

$$x_1(t) = T(t)$$

$$x_2(t) = \dot{T}(t)$$

Por lo tanto, el modelo permite analizar no solo el valor de la temperatura, sino también la rapidez con la que el horno se está calentando o enfriando.

4.2 Diseño del controlador por localización arbitraria de polos

Con el modelo en espacio de estados ya definido, se diseñó un controlador por realimentación de estados. El objetivo fue que el horno pudiera seguir una referencia de temperatura de forma estable, sin oscilaciones importantes y sin sobreimpulso significativo.

Para lograrlo, se utilizó una ley de control que combina la realimentación de estados con una ganancia de prealimentación N . La realimentación de estados permite modificar la dinámica del sistema en lazo cerrado, mientras que N ayuda a mejorar el seguimiento de la referencia.

El comportamiento deseado se definió mediante un sistema de segundo orden con amortiguamiento crítico. Esta elección es adecuada para el horno, ya que se busca una respuesta lenta y estable, evitando cambios bruscos de temperatura.

A partir del polinomio característico deseado, se calculó la matriz de ganancias del controlador usando la fórmula de Ackermann. Con esto fue posible colocar los polos del sistema en la posición deseada y obtener una respuesta adecuada para el proceso térmico.

La ley de control utilizada fue:

$$u(t) = Nr(t) - K_c x(t)$$

donde $r(t)$ es la referencia de temperatura, N es la ganancia de prealimentación del sistema y K_c es la matriz de ganancias del controlador.

Sustituyendo la ley de control en el modelo original,

$$\dot{x}(t) = Ax(t) + Bu(t)$$

se obtiene:

$$\begin{aligned} \dot{x}(t) &= Ax(t) + B(Nr(t) - K_c x(t)) \\ \dot{x}(t) &= (A - BK_c)x(t) + BNr(t) \end{aligned}$$

Por lo tanto, la matriz que define el comportamiento del sistema en lazo cerrado es:

$$A_c = A - BK_c$$

Para definir la respuesta deseada se eligió un sistema de segundo orden con amortiguamiento crítico:

$$\begin{aligned}\zeta &= 1 \\ \omega_n &= 0.000667\end{aligned}$$

Se escogió $\zeta = 1$ porque se buscaba una respuesta sin oscilaciones y sin sobreimpulso importante. Esto es conveniente para un horno de sostenimiento, ya que no se quiere que la temperatura suba de forma brusca ni que sobrepase demasiado el valor deseado.

El polinomio característico deseado fue:

$$p_d(s) = s^2 + 2\zeta\omega_n s + \omega_n^2$$

Sustituyendo los valores usados:

$$p_d(s) = s^2 + 1.334 \times 10^{-3}s + 4.44889 \times 10^{-7}$$

Por lo tanto, los polos deseados del controlador quedaron como:

$$p_1 = p_2 = -0.000667$$

Para calcular la matriz K_c , primero se evaluó el polinomio deseado en la matriz A :

$$\Phi(A) = A^2 + 1.334 \times 10^{-3}A + 4.44889 \times 10^{-7}I$$

Después se construyó la matriz de controlabilidad:

$$\mathcal{C}_c = [B \quad AB]$$

Finalmente, se aplicó la fórmula de Ackermann:

$$K_c = [0 \quad 1] \mathcal{C}_c^{-1} \Phi(A)$$

Con este procedimiento se obtuvo:

$$K_c = [-1.407 \times 10^{-6} \quad -0.0056104]$$

También se calculó el prefiltro N , con el objetivo de mejorar el seguimiento de la referencia y reducir el error estacionario:

$$N = -\frac{1}{C(A - BK_c)^{-1}B}$$

El valor obtenido fue:

$$N = 3.4767 \times 10^{-4}$$

Así, la ley de control final quedó como:

$$u(t) = 3.4767 \times 10^{-4}r(t) - \begin{bmatrix} -1.407 \times 10^{-6} & -0.0056104 \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix}$$

o de forma desarrollada:

$$u(t) = 3.4767 \times 10^{-4}r(t) + 1.407 \times 10^{-6}x_1(t) + 0.0056104x_2(t)$$

Con este controlador, el sistema en lazo cerrado busca seguir la referencia de temperatura de manera estable y sin sobreimpulso significativo, manteniendo una dinámica lenta y razonable para un horno de sostenimiento.

4.3 Incorporación de perturbaciones

En esta sección se agregan perturbaciones simples al modelo para representar condiciones no ideales del proceso. La intención no es describir de manera exacta todos los fenómenos físicos del horno, sino probar si el controlador mantiene una respuesta estable ante variaciones externas.

Se consideraron dos perturbaciones. La primera representa una posible fuga o extracción de aluminio líquido. Esta perturbación se agregó directamente en la dinámica del sistema, ya que una fuga o extracción puede afectar la evolución térmica del horno.

La segunda perturbación representa efectos asociados al refractario y al ambiente. Esta se agregó en la salida del sistema, porque puede interpretarse como una variación térmica observada en la medición o en la respuesta final de la temperatura.

Estas perturbaciones no buscan modelar todos los fenómenos físicos del horno sino probar si el controlador mantiene una respuesta estable ante variaciones externas.

Con estas perturbaciones, el sistema permite evaluar si el controlador conserva estabilidad y seguimiento de referencia aun cuando se agregan variaciones externas al modelo.

La perturbación de fuga se representa como:

$$d_{\text{fuga}}(t)$$

La perturbación del refractario se representa como:

$$d_{\text{refractario}}(t)$$

La perturbación de fuga se agregó directamente en la dinámica del sistema, ya que una fuga o extracción de aluminio puede afectar la evolución de la temperatura del horno. Por otro lado, la perturbación del refractario se agregó en la salida, porque representa variaciones térmicas asociadas al recubrimiento interno del horno y al ambiente.

Ambas perturbaciones se modelaron en Simulink usando bloques de número aleatorio con distribución normal. Para las dos señales se utilizó la misma configuración:

$$\begin{aligned}\mu &= 0 \\ \sigma^2 &= 0.01 \\ T_s &= 0.1 \text{ s}\end{aligned}$$

Aquí la media igual a cero indica que la perturbación oscila alrededor de cero, sin una tendencia fija positiva o negativa. La varianza define la magnitud de las variaciones aleatorias, y el tiempo de muestreo indica que la señal se actualiza cada 0.1 segundos.

Con estas perturbaciones, el modelo queda representado como:

$$\begin{aligned}\dot{x}(t) &= Ax(t) + Bu(t) + B d_{\text{fuga}}(t) \\ y(t) &= Cx(t) + d_{\text{refractario}}(t)\end{aligned}$$

4.4 Observador de estados

Además del controlador, se diseñó un observador de estados. Su objetivo es estimar variables internas del sistema que no siempre pueden medirse directamente en un proceso real.

El observador utiliza el modelo matemático, la entrada del sistema y la diferencia entre la salida real y la salida estimada. Esta diferencia permite corregir la estimación de los estados. Para que la estimación convergiera rápidamente, se eligieron polos del observador más rápidos que la dinámica térmica del horno.

En la simulación se compararon los estados reales con los estados estimados, observando señales muy similares. Esto muestra que el observador cumple su función como sensor virtual dentro del sistema de control.

El observador se definió como:

$$\dot{\hat{x}}(t) = A\hat{x}(t) + Bu(t) + L(y(t) - \hat{y}(t))$$

La salida estimada se calculó como:

$$\hat{y}(t) = C\hat{x}(t)$$

El termino de coreccion del observador es:

$$y(t) - \hat{y}(t)$$

Este término representa el error entre la salida real del sistema y la salida estimada por el observador. Si existe una diferencia entre ambas, la matriz L corrige la estimación de los estados.

Para diseñar el observador se eligieron polos en:

$$\begin{aligned}p_1 &= -1 \\ p_2 &= -1\end{aligned}$$

Estos polos se eligieron porque son mucho más rápidos que la dinámica térmica del horno. Como el horno responde lentamente, colocar los polos del observador en -1 hace que la estimación converja rápidamente hacia los estados reales.

El polinomio deseado del observador fue:

$$\begin{aligned} p_o(s) &= (s + 1)^2 \\ p_o(s) &= s^2 + 2s + 1 \end{aligned}$$

La matriz L se obtuvo imponiendo que los polos de $A - LC$ coincidieran con los polos deseados:

$$\det(sI - (A - LC)) = s^2 + 2s + 1$$

Con este procedimiento se obtuvo:

$$L = \begin{bmatrix} 5.6281 \times 10^4 \\ 364.955 \end{bmatrix}$$

Por lo tanto el observador final queda como:

$$\begin{aligned} \dot{\hat{x}}(t) &= A\hat{x}(t) + Bu(t) + \begin{bmatrix} 5.6281 \times 10^4 \\ 364.955 \end{bmatrix} (y(t) - \hat{y}(t)) \\ \hat{y}(t) &= C\hat{x}(t) \end{aligned}$$

En la simulación se comparó el estado real $x_1(t)$ con el estado estimado $\hat{x}_1(t)$, así como el estado real $x_2(t)$ con su estimación $\hat{x}_2(t)$. En ambos casos, las señales mostraron un comportamiento muy similar, lo cual indica que el observador logra reconstruir adecuadamente los estados internos del horno.

Esto confirma que el observador cumple su función dentro del sistema de control moderno, ya que permite estimar variables que no necesariamente se medirían directamente en un sistema real.

4.5 Implementación en Simulink

El modelo se implementó en Simulink usando integradores, ganancias y sumadores. Los integradores representan la evolución de los estados, mientras que las ganancias corresponden a los coeficientes de las matrices del sistema, la realimentación de estados y la ganancia de prealimentación.

La implementación general muestra el sistema de control del horno y el observador de estados. El bloque interno del horno contiene directamente las ecuaciones del modelo en espacio de estados, junto con las perturbaciones agregadas para validar el comportamiento del controlador.

Antes de implementar el sistema en Simulink, se escribieron las ecuaciones escalares del modelo en espacio de estados. A partir de las matrices obtenidas, el sistema queda:

$$\begin{aligned} \dot{x}_1(t) &= x_2(t) \\ \dot{x}_2(t) &= -1.852 \times 10^{-6} x_1(t) - 0.006944 x_2(t) + u(t) + d_{\text{fuga}}(t) \\ y(t) &= 0.001296 x_1(t) - 0.1944 x_2(t) + d_{\text{refractario}}(t) \end{aligned}$$

La señal de control se implementó como:

$$u(t) = Nr(t) + K_s x(t)$$

donde:

$$K_s = \begin{bmatrix} 1.407 \times 10^{-6} & 0.0056104 \end{bmatrix}$$

$$N = 3.4767 \times 10^{-4}$$

Por lo tanto, la ecuación de entrada al sistema queda:

$$u(t) = 3.4767 \times 10^{-4}r(t) + 1.407 \times 10^{-6}x_1(t) + 0.0056104x_2(t)$$

Estas ecuaciones fueron las que se representaron en Simulink mediante integradores, ganancias y sumadores. Los integradores permiten obtener los estados $x_1(t)$ y $x_2(t)$, mientras que las ganancias representan los coeficientes de las matrices A , B , C , el prefiltro N y la realimentación de estados.

En la Figura 1 se muestra la implementación general del sistema en Simulink. La parte superior corresponde al sistema de control del horno de sostenimiento, mientras que la parte inferior corresponde al observador de estados. Esta estructura permite visualizar cómo la referencia entra al controlador, cómo se genera la respuesta del horno y cómo el observador estima los estados internos del sistema.




Figure 1: Implementación general del sistema de control moderno y del observador de estados en Simulink.

En la Figura 2 se muestra el interior del bloque correspondiente al modelo del horno. En este diagrama se observa cómo se implementaron las ecuaciones anteriores mediante

integradores y ganancias. También se incluyen la realimentación de estados, el prefiltro de referencia y las perturbaciones de fuga y refractario usadas en la simulación.




Figure 2: Implementación interna del modelo en espacio de estados del horno de sostenimiento.

Esta implementación permitió validar de forma visual y numérica el comportamiento del sistema de control. A partir de las simulaciones se observó que el controlador mantiene la temperatura cercana al punto de operación de $700^{\circ}C$, mientras que el observador logra estimar los estados internos con señales similares a las del modelo original.

4.6 Desempeño del sistema

Para evaluar el sistema, se utilizó una referencia de temperatura de $700^{\circ}C$. La respuesta obtenida se mantuvo cerca del punto de operación, sin oscilaciones importantes y sin sobreimpulso significativo.

Este comportamiento es consistente con el amortiguamiento crítico elegido para el diseño. Además, el tiempo de asentamiento obtenido es razonable para un horno de sostenimiento, ya que este tipo de proceso térmico debe responder de forma lenta y estable.

En las simulación se utilizó una referencia de temperatura de:

$$r(t) = 700^{\circ}C$$

El sistema logró mantenerse cerca del punto de operación, sin oscilaciones importantes ni sobreimpulso significativo. Esto coincide con el diseño del controlador, ya que se eligió un amortiguamiento crítico:

$$\zeta = 1$$

Con este valor de amortiguamiento se busca que la respuesta sea estable y no oscilatoria. Por esta razón, el sobreimpulso máximo fue prácticamente nulo:

$$M_p \approx 0\%$$

El tiempo de asentamiento observado en la simulación fue aproximadamente:

$$T_s \approx 12000 \text{ s}$$

$$T_s \approx 3.3 \text{ h}$$

Este comportamiento es razonable para un horno de sostenimiento, ya que el proceso térmico debe responder de manera lenta y estable. En general, la simulación muestra que el controlador puede mantener la temperatura cerca de 700°C , incluso al agregar perturbaciones simples al modelo.

En la Figura 8 se muestra la respuesta del sistema sin perturbaciones ante una referencia de 700°C . Se observa que la salida alcanza el valor de referencia de manera suave, sin oscilaciones importantes y sin sobreimpulso significativo. Además, el error estacionario obtenido fue muy bajo, aproximadamente de 0.05°C , lo cual indica que el controlador logra un seguimiento preciso de la referencia.




Figure 3: Respuesta del sistema sin perturbaciones ante una referencia de 700°C .

4.7 Cierre de la solución de control

Con base en el modelado, el diseño del controlador y las simulaciones realizadas, se considera que la solución de control propuesta es adecuada para el problema del horno de sostenimiento. El modelo en espacio de estados permitió representar la dinámica térmica del sistema y aplicar una estrategia de control moderno mediante realimentación de estados.

El controlador diseñado logró que la temperatura siguiera la referencia de 700°C de forma estable, sin oscilaciones importantes y sin sobreimpulso significativo. Además, el uso de la ganancia de prealimentación ayudó a reducir el error estacionario, obteniendo una respuesta cercana al punto de operación.

También se incorporaron perturbaciones simples para evaluar el comportamiento del sistema ante variaciones externas, y se diseñó un observador de estados para estimar variables internas del modelo. Por lo tanto, la propuesta no solo es funcional, sino que integra los elementos principales esperados en una solución de control moderno: modelado matemático, diseño del controlador, validación en simulación y análisis del desempeño.

5 Análisis Exploratorio de Datos

El conjunto de datos corresponde al `dataset_horno_sostenimiento2_CORREGIDO.csv`. Consiste en 20,160 observaciones muestreadas con una frecuencia de 1 minuto durante un periodo de 14 días (2026-05-01 al 2026-05-14). Contiene 11 variables categorizadas en

- salidas: temperaturas principal (`sensor_temp_main`) y respaldo (`sensor_temp_backup`)
- referencia: `setpoint`
- control: potencia del calentador (`heater_power_pct`)
- eléctricas: corriente, (`electrical_current`) y voltaje (`electrical_voltage`)
- perturbaciones: nivel de aluminio (`aluminum_level_pct`), temperatura ambiente (`ambient_temp`), tasa de extracción (`production_draw_rate`), cubierta abierta (`lid_open_pct`)
- derivadas: consumo de energía (`energy_consumption_kWh`)

	count	mean	std	min	25%	50%	75%	max
<code>sensor_temp_main</code>	19844.0	637.316	57.922	501.284	568.122	674.425	676.404	704.138
<code>sensor_temp_backup</code>	19954.0	634.391	57.597	509.628	566.988	671.505	673.370	693.800
<code>setpoint</code>	20160.0	700.000	0.707	699.000	699.293	700.000	700.707	701.000
<code>heater_power_pct</code>	20160.0	83.777	14.212	0.000	75.798	79.012	100.000	100.000
<code>electrical_current</code>	20160.0	90.264	13.732	0.000	83.130	86.441	103.889	110.596
<code>electrical_voltage</code>	20160.0	439.972	3.340	429.239	437.360	440.004	442.574	450.123
<code>lid_open_pct</code>	20160.0	3.764	6.259	0.000	1.462	2.102	2.818	50.037
<code>ambient_temp</code>	20160.0	24.002	3.553	17.925	20.474	23.996	27.517	30.059
<code>production_draw_rate</code>	20160.0	0.378	1.100	0.000	0.000	0.000	0.000	4.833
<code>aluminum_level_pct</code>	20160.0	90.305	8.413	30.557	90.412	93.452	93.993	94.000
<code>energy_consumption_kWh</code>	20160.0	1.147	0.175	0.000	1.055	1.101	1.316	1.424

Table 1: Estadísticas descriptivas de las variables del proceso

En la Tabla 1 se indica que la temperatura principal tiene una media de 637.3 °C con una desviación estándar de 57.9 °C. El *setpoint* se mantiene constante alrededor de los 700 °C. La potencia del calentador tiene un uso medio del 83.7% y el consumo energético promedio es de 1.147 kWh.

	nulos	pct
<code>sensor_temp_main</code>	316	1.57
<code>sensor_temp_backup</code>	206	1.02
<code>setpoint</code>	0	0.00
<code>heater_power_pct</code>	0	0.00
<code>electrical_current</code>	0	0.00
<code>electrical_voltage</code>	0	0.00
<code>lid_open_pct</code>	0	0.00
<code>ambient_temp</code>	0	0.00
<code>production_draw_rate</code>	0	0.00
<code>aluminum_level_pct</code>	0	0.00
<code>energy_consumption_kWh</code>	0	0.00

Table 2: Null summary

No existen timestamps duplicados. Se identificaron valores nulos concentrados exclusivamente en los sensores de temperatura: la temperatura principal presentó 316 datos faltantes (1.57%) y la de respaldo 206 faltantes (1.02%), los cuales se agrupan en bloques.




Figure 4: Histogramas y funciones de densidad

Se puede observar en las distribuciones de temperatura **main** y **backup** que están marcadas por una asimetría negativa. La moda y mediana, se encuentran concentradas fuertemente en la región de alta temperatura. Sin embargo, también se puede observar que existe una cola extendida hacia la izquierda, esta representa las trayectorias transitorias en las que el sistema abandona su equilibrio termodinámico debido a caídas bruscas de calor, como es la apertura del horno o la reinserción de aluminio. La distribución de la potencia del calentador, presenta un sesgo negativo evidente, aglomerando la mayor parte de las observaciones en el rango superior, con una media de uso del 83.77%. Esta concentración asimétrica nos dice que este opera cerca de su límite de saturación la mayor parte del tiempo para sostener el calor latente del aluminio.

En el histograma del nivel de aluminio, se puede observar una distribución leptocúrtica con valores puntuales y aislados en los extremos. Esto nos indica que la masa de aluminio permanece constante durante largos períodos y experimenta funciones de escalón decreciente, las cuales serían las descargas de material, lo cual actúa como una perturbación determinista exógena que extrae bruscamente la cantidad de energía térmica que contiene el horno de un segundo a otro.

En la distribución de corriente, se percibe una distribución bimodal, característico de sistemas con lógicas discretas. Se puede decir que el sistema eléctrico conmuta drásticamente entre umbrales definidos para suministrar la potencia demanda. Los componentes eléctricos se encienden al 100% o se apagan muy rápido para mantener el calor. Mientras que

el histograma de la temperatura, se observa una distribución bimodal, reflejando el ciclo natural de los 14 días, madrugadas más frías y temperaturas más cálidas a mediodía.

	Skew	Kurtosis
sensor_temp_main	-0.966	-0.880
sensor_temp_backup	-0.969	-0.877
heater_power_pct	-1.595	8.526
electrical_current	-2.344	14.403
electrical_voltage	-0.016	-0.724
lid_open_pct	3.619	13.266
ambient_temp	-0.002	-1.470
production_draw_rate	2.828	6.694
aluminum_level_pct	-4.201	20.281

Table 3: Coeficientes de asimetría (skewness) y curtosis de las variables

Esto refuerza la historia que estábamos viendo con los histogramas. Nos enfrentamos a distribuciones que se alargan hacia los valores menores, empujando la mayor concentración de datos hacia el lado derecho de la gráfica. Es coherente que `lid_open_pct` y que `production_draw_rate` tengan una asimetrías positivas, pues se hacen contadas veces durante el día y solo cuándo es necesario. La asimetría negativa observada en `heater_power_pct` indica que el actuador opera sistemáticamente cerca de su saturación para vencer las pérdidas por los mecanismos físicos por los cuales el horno pierde energía térmica hacia el ambiente exterior, obligando al sistema a inyectar potencia continuamente para mantener el metal fundido.

El exceso de kurtosis en `heater_power_pct`, `electrical_current`, `lid_open_pct`, `production draw rate`, `aluminum_level_pct`, define una distribución fuertemente leptocúrtica, garantizando una concentración masiva de datos en un punto central sumamente estrecho y una alta probabilidad de eventos extremos muy alejados de la media. Por su parte, la leptocurtosis extrema en el `aluminum_level_pct` y en `production_draw_rate` captura el comportamiento de perturbaciones deterministas exógenas: la masa térmica permanece constante durante periodos prolongados hasta que las descargas de material extraen la cantidad de energía térmica del sistema de manera súbita y localizada, generando colas pesadas de baja probabilidad pero de alto impacto dinámico. Y las demás también las describimos arriba.




Figure 5: Comportamiento temporal de las variables principales del horno durante los 14 días analizados.

En esta gráfica se muestra el comportamiento del horno durante los catorce días, se integran variables térmicas, eléctricas y operativas. Es importante tener en cuenta que todas las señales están relacionadas: la temperatura depende de la energía suministrada, la energía depende de la corriente y el voltaje, además de que cualquier intervención operativa, como abrir una tapa o cargar material, se termina reflejando en la temperatura.

La primera gráfica representa la temperatura. La línea negra representa el setpoint, las líneas azul y naranja corresponden a los sensores *main* y *backup*. Ambos sensores prácticamente se superponen durante todo el período, esto indica consistencia en la medición y reduce la probabilidad de que exista un sensor defectuoso. También es posible observar que la temperatura real se mantiene entre 650°C y 685°C, por debajo del setpoint. El sistema no está alcanzando el valor deseado y el actuador opera sistemáticamente cerca de su saturación. Los coeficientes de asimetría negativos observados en *heater_power_pct* (-1.595) y *electrical_current* (-2.344) indican que ambas variables permanecen gran parte del tiempo en valores elevados. Este comportamiento, junto con la diferencia persistente entre la temperatura medida y el setpoint, sugiere que el sistema podría estar operando cerca de su capacidad térmica nominal. Sin embargo, los estadísticos de distribución por sí solos no permiten confirmar una condición de saturación, por lo que sería necesario analizar la respuesta del controlador, la potencia máxima instalada y el balance térmico del proceso.


La segunda gráfica muestra el porcentaje de calentamiento y la corriente consumida. Describen el esfuerzo que está realizando el sistema para mantener la temperatura. La línea roja/verde es la potencia aplicada a los calentadores, mientras que el eje derecho

representa la corriente consumida. Cuando el horno se encuentra recuperándose después de una caída térmica, el porcentaje de calentamiento se acerca al 100%. El controlador solicita la máxima potencia disponible para estabilizar la temperatura del horno. A medida que la temperatura se estabiliza, el porcentaje disminuye hasta valores cercanos al 75%-90%. La corriente sigue el mismo comportamiento que el calentamiento. La correlación entre ambas señales confirma que los elementos calefactores están respondiendo correctamente a las órdenes del controlador. Esto es importante porque sugiere que el sistema de potencia funciona adecuadamente y que no existen calentadores desconectados o fallas evidentes en los actuadores. Existen además, tres momentos específicos en los que tanto el calentamiento como la corriente, caen instantáneamente a cero. Estos eventos son demasiado abruptos para corresponder a un fenómeno térmico normal y apuntan más bien a una interrupción eléctrica. Podría tratarse de un reinicio del controlador, una parada de emergencia, la actuación de una protección eléctrica o incluso una breve pérdida de alimentación. Como la recuperación ocurre rápidamente, parece que no se trata de una falla grave sino de eventos transitorios que deberían investigarse en los registros de alarmas del sistema.

La tercera gráfica presenta el voltaje de alimentación. Se observa una oscilación periódica entre aproximadamente 432 y 447 V. El comportamiento es bastante uniforme durante todo el período. Lo importante aquí es que no aparecen caídas extremas ni interrupciones prolongadas. Si el voltaje fuera la causa principal de los problemas térmicos se esperarían reducciones sostenidas o eventos coincidentes con las caídas de temperatura, algo que no se aprecia claramente. Por lo tanto, el suministro eléctrico parece suficientemente estable para la operación normal del horno.

La cuarta gráfica contiene las variables de `lid_open_pct`, `production_draw_rate` y `aluminum level_pct`. Durante la mayor parte del tiempo la cantidad de aluminio dentro del horno se mantiene entre 80% y 95%, lo que sugiere una condición de operación estable. Es importante denotar los múltiples picos en cada vez el horno es abierto, incluso en períodos cortos, se produce una transferencia intensa de calor hacia el ambiente. Por esta razón, es fácil pensar que existe algún tipo de correlación entre aperturas frecuentes y pequeñas fluctuaciones de temperatura que tal vez impidan que el horno llegue al setpoint.

Desde una perspectiva global, la gráfica describe un proceso térmico razonablemente estable, donde los sensores funcionan correctamente y el sistema de potencia responde de manera coherente. Los principales eventos de interés son las grandes caídas de temperatura asociadas probablemente a actividades operativas y los breves episodios en los que corriente y calentamiento caen a cero. Además, resulta especialmente relevante que el horno opere persistentemente por debajo del setpoint.



La correlación de Pearson entre `sensor_temp_main` y `sensor_temp_backup` es 0.997, mientras que la de Spearman es 0.973. Ambos valores son extremadamente altos y positivos, lo que indica que los dos sensores registran prácticamente el mismo comportamiento térmico durante todo el período analizado. Las conclusiones obtenidas a partir de la temperatura difícilmente pueden atribuirse a errores de medición o a la falla de uno de los sensores, ya que ambos muestran tendencias casi idénticas.

La correlación de Pearson entre `sensor_temp_main` y `heater_power_pct` es -0.764, mientras que Spearman alcanza -0.839. Esto significa que cuando la temperatura disminuye, el controlador aumenta la potencia del calentador para recuperar el setpoint. Cuando la temperatura aumenta, el controlador reduce la potencia suministrada. Implicando que el controlador está funcionando correctamente. No existe evidencia de que ignore el error térmico. Por el contrario, responde de forma agresiva cuando la temperatura cae. Además, el hecho de que Spearman sea más fuerte que Pearson sugiere que la relación es muy consistente en términos de tendencia, aunque no necesariamente perfectamente lineal.

La correlación entre `heater_power_pct` y `electrical_current` es probablemente el resultado más importante de toda la matriz. Pues esos valores tan altos, $r = 0.990$ y $\rho = 0.945$, indica una dependencia casi perfecta. Esto significa que cuando el controlador aumenta la potencia demandada, la corriente consumida por el sistema aumenta proporcionalmente. Representa lo que ocurre un horno que funciona perfectamente. Por lo tanto, esta relación confirma que el porcentaje de calentamiento realmente representa una demanda energética real.

La variable `lid_open_pct` muestra correlaciones extremadamente bajas con la temperatura, $r = 0.006$ y $\rho = -0.019$, esto no necesariamente signifique que abrir la compuerta no afecte la temperatura. Lo que podría indicar es que las aperturas registradas son demasiado breves para producir una relación global detectable mediante correlación, pues como se pudo observar en la Figura 8 son bastante frecuentes. Las correlaciones capturan patrones generales durante todo el período, por lo que eventos puntuales suelen perderse dentro del conjunto completo de datos.

La variable `aluminum_level_pct` presenta correlaciones moderadas bajas con temperatura $r = 0.293$ y $\rho = 0.235$, con potencia $r = -0.299$ y $\rho = -0.298$, y con corriente $r = -0.282$ y $\rho = -0.268$. Físicamente son interesantes porque nos dicen que cuando el nivel de

aluminio aumenta: la temperatura tiende a ser ligeramente mayor, la potencia requerida y la corriente consumida tienden a disminuir. Esto nos podría decir, que los períodos de nivel alto coinciden con estados más estables del proceso, mientras que los niveles bajos aparecen durante operaciones de vaciado o perturbaciones que exigen mayor esfuerzo térmico para recuperar las condiciones normales.

Los resultados muestran que el comportamiento del horno está dominado principalmente por la interacción entre temperatura, potencia de calentamiento y corriente eléctrica. Las correlaciones fuertes entre estas variables demuestran que el sistema de control responde adecuadamente a las desviaciones térmicas y que el sistema eléctrico acompaña correctamente dicha respuesta. Por otro lado, variables externas como el voltaje de alimentación, la temperatura ambiente, la apertura de la tapa y la tasa de extracción presentan relaciones muy débiles con la temperatura del horno, lo que indica que no son los principales factores que explican las variaciones observadas.




Figure 7: Análisis de autocorrelación

Podemos ver una ACF que decrece muy lentamente, que nunca cruza 0.75 dentro del rango. Esto indica que la serie posee una inercia extremadamente alta y una memoria temporal muy prolongada. También se puede observar que, la PACF tiene un pico muy alto en los primeros retardos y una caída rápida posteriormente, eso indicaría que el comportamiento inmediato del horno depende principalmente de su estado reciente. Si, por el contrario, la PACF permanece elevada durante muchos retardos, sugeriría una dinámica más compleja o la presencia de tendencias y ciclos operativos prolongados.

ACF < 0.5 en lag =	None min
ACF < 0.2 en lag =	None min

Table 4: Resultados de autocorrelación de la temperatura principal.

El hecho de que la ACF nunca caiga por debajo de 0.5 ni de 0.2 en los retardos analizados indica una memoria temporal extremadamente larga. Esto sugiere que el estado actual del horno está influenciado por condiciones ocurridas mucho tiempo atrás. Este fenómeno es característico de sistemas con elevada inercia térmica, donde la energía almacenada en la estructura y en el material procesado amortigua los cambios rápidos de temperatura.

ADF stats:	-1.8622
p-value:	3.5004e-01
No estacionaria	

Table 5: Prueba ADF aplicada a la temperatura principal.

La prueba ADF (Aumented Dickey-Fuller) se utiliza para determinar si una serie temporal es estacionaria. Una serie estacionaria es aquella cuyas propiedades estadísticas fundamentales, como la media, la varianza y la estructura de correlación, permanecen aproximadamente constantes a lo largo del tiempo. La estacionariedad implica que el sistema oscila alrededor de un punto de operación relativamente estable sin presentar tendencias persistentes de crecimiento o decrecimiento. La hipótesis nula de la prueba establece que la serie es no estacionaria. Dado que el $p - value$ es considerablemente mayor que el nivel de significancia convencional de 0.05, no existe evidencia estadística suficiente para rechazar dicha hipótesis.

Este resultado indica que la temperatura del horno presenta comportamiento no estacionario. Desde una perspectiva física, este hallazgo es coherente con la operación observada en las gráficas temporales. Durante el período analizado se identificaron fases de calentamiento, caídas abruptas de temperatura, recuperaciones posteriores y cambios asociados a perturbaciones operativas. Todos estos fenómenos provocan modificaciones en la media de la serie a lo largo del tiempo, violando el supuesto de estacionariedad. Pues, el horno alterna entre distintos regímenes operativos que modifican su comportamiento estadístico.

5.1 Evaluación del horno

Con el objetivo de evaluar si el horno era capaz de alcanzar la temperatura de referencia bajo condiciones de máxima demanda energética, se calculó el error de control como la diferencia entre el setpoint y la temperatura medida por el sensor principal:

$$e(t) = T_{SetPoint} - T_{Real}$$

donde $T_{SetPoint} = 700\text{ }^{\circ}\text{C}$ y T_{Real} corresponde a la temperatura registrada por el sensor principal del horno. Un valor positivo del error indica que la temperatura real se encuentra por debajo de la temperatura objetivo. Para evitar que los períodos de arranque y recuperación influyeran en el análisis, únicamente se consideraron observaciones correspondientes a condiciones cercanas al régimen estacionario ($T_{real} > 650\text{ }^{\circ}\text{C}$). Adicionalmente, se seleccionaron los instantes en los que el sistema de calentamiento operaba prácticamente a su máxima capacidad ($heater_power_pct \geq 95\%$). Sobre este subconjunto de datos se calculó el error promedio, obteniéndose un valor de:

$$\bar{e} = 40.93^\circ\text{C}$$

Este resultado indica que, aun cuando el controlador solicita prácticamente la máxima potencia disponible al sistema de calentamiento, la temperatura del horno permanece en promedio aproximadamente 41°C por debajo de la temperatura objetivo. En términos operativos, esto implica que el incremento de potencia aplicado por el controlador no es suficiente para eliminar completamente el error de temperatura. Un hallazgo adicional relevante es que el calentador opera por encima del 95% de su capacidad durante el 33.19% del tiempo analizado. Este porcentaje es considerablemente elevado para un sistema diseñado para mantener una operación estable alrededor de un punto de consigna. La combinación de una alta operación del calentador y la persistencia de un error positivo significativo sugiere que el sistema trabaja frecuentemente cerca de su límite de capacidad térmica.




Figure 8: Heatmap de correlación entre error_temp y heater_power_pct

La correlación calculada entre el error de temperatura y la potencia del calentador fue de $r = 0.764$, lo que indica una relación positiva fuerte entre ambas variables. Este resultado demuestra que el controlador responde adecuadamente al incremento del error, aumentando la potencia suministrada cuando la temperatura se aleja del valor objetivo. Por tanto, la presencia del error residual no parece asociarse a una falta de respuesta del controlador, sino a una limitación física del proceso o a pérdidas térmicas que no pueden ser compensadas completamente por el sistema de calentamiento. En conjunto, estos resultados constituyen evidencia de que el horno opera durante una fracción importante del tiempo bajo condiciones cercanas a saturación térmica. Aunque esta situación no permite afirmar de manera concluyente que la potencia instalada sea insuficiente, sí puede llegar a indicar que la capacidad disponible es casi explotada y que existe una diferencia persistente entre la temperatura objetivo y la temperatura alcanzada durante los periodos de máxima demanda energética. Esto puede estar asociado a limitaciones de potencia, pérdidas de calor elevadas o perturbaciones operativas frecuentes, como aperturas de tapa que es lo que se pudo observar en la Figura 8.

5.2 Hallazgos principales

- El horno opera lejos del setpoint y el actuador se satura.

El horno tiene una temperatura promedio de 637°C cuando la referencia está en 700°C con caídas hasta 501°C . El comportamiento del horno demostró que más del 25% del tiempo operaba a su máxima capacidad. En base a esto podemos concluir que el forecasting es una opción prometedora para el control de fugas en el transcurso del horario de operación con el horno encendido.

- Memoria térmica muy larga y no estacionariedad.

Mediante el análisis de autocorrelación(ACF), se descubrió que el horno tiene una memoria efectiva que supera las 12 horas. La ‘memoria’ se refiere a la inercia térmica del aluminio y la estructura del horno es muy alta, lo que significa que los eventos del pasado afectan el comportamiento presente mucho tiempo después de haber ocurrido. De igual forma, las pruebas estadísticas ADF confirmaron que el comportamiento del horno no es estacionario; es decir, las dinámicas no se mantienen constantes y cambian en los días de operación. Este hallazgo refleja la importancia de analizar el comportamiento de una red neuronal incorporando memoria como una LSTM(Long Short-Term Memory), ya que su diseño le permite retener contexto histórico y comprender cómo el pasado afecta el futuro del horno.

- Fuerte redundancia multivariable.

Las 11 variables que tiene el dataset original mostraron una alta correlación entre ellas. Variables como la potencia, voltaje y corriente denotaban el mismo comportamiento físico (energía). Lo mismo ocurre con los dos sensores de temperatura que arrojan lecturas casi idénticas. Para obtener lo más valioso de los datos, aplicamos un análisis de componentes principales(PCA), de los cuales 8 componentes son suficientes para explicar más del 95% del comportamiento total del sistema. Este hallazgo es de suma importancia ya que define la arquitectura de la red neuronal(Autoencoder), ya que proporciona un argumento cuantitativo y matemático. Una vez definido el tamaño de comprensión de la red, se configura el espacio latente exactamente a 8 dimensiones, que representan el comportamiento físico más relevante del horno mientras filtra el ruido externo.

5.3 Disponibilidad de los datos

El conjunto de datos analizados pertenecen a los datos recolectados durante catorce días, con una frecuencia de un minuto, por la empresa Ronald Group. El código y los datos para su reproducción están disponibles en https://github.com/Facundo-Barbera/reto_MA2008B

6 Selección y Justificación del Modelo de Deep Learning

Para seleccionar y justificar el uso de un modelo basado en Deep Learning, se realizó inicialmente un Análisis de Componentes Principales (PCA) con el fin de explorar la estructura subyacente de los datos. Los resultados mostraron que gran parte de la variabilidad del proceso podía concentrarse en un número reducido de componentes principales, lo que sugiere la existencia de una estructura latente comprimible. Sin embargo, debido a que el PCA es una técnica lineal, su capacidad para representar fenómenos complejos se encuentra limitada cuando existen dependencias temporales, retardos dinámicos e interacciones no lineales entre las variables del proceso.




Figure 9: Análisis de PCA

La Figura 9 nos mostró que, aunque existe cierta redundancia entre variables, el sistema requiere al menos 8 componentes lineales para preservar más del 95% de la varianza y lograr una reconstrucción con error prácticamente nulo. Esto sugiere que la dinámica del horno no puede representarse adecuadamente mediante un espacio latente lineal de baja dimensión. Además, la no estacionariedad detectada mediante la prueba ADF, la persistencia temporal observada en la ACF y la evidencia de saturación térmica indican la presencia de dependencias temporales largas y no linealidades operativas. En conjunto, estos resultados justifican el uso de modelos de Deep Learning, ya que arquitecturas no lineales como autoencoders, LSTM o Transformers pueden capturar relaciones complejas, efectos transitorios y patrones multivariantes que métodos lineales como PCA no logran modelar eficientemente.

Variable	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8
sensor_temp_main	-0.416425	0.136367	-0.064053	-0.071737	0.175950	-0.065386	-0.001202	0.518326
sensor_temp_backup	-0.419262	0.133726	-0.060021	-0.068632	0.175849	-0.062634	-0.008436	0.504567
setpoint	0.008735	0.565047	0.511107	-0.045688	-0.254059	-0.324934	0.495951	-0.035015
heater_power_pct	0.456871	0.002285	-0.082436	-0.002364	0.076101	-0.077144	0.080014	0.259177
electrical_current	0.448523	0.005185	-0.095184	-0.010014	0.094153	-0.092819	0.095425	0.339248
electrical_voltage	0.012497	0.500292	-0.424943	-0.005593	-0.157827	0.695709	0.239904	-0.031916
aluminum_level_pct	-0.186730	-0.378167	-0.377128	0.123139	0.136037	-0.194276	0.766206	-0.146094
ambient_temp	-0.058320	-0.088992	-0.007078	0.820099	-0.496828	-0.013146	-0.059801	0.255857
energy_consumption_kwh	0.447895	0.030067	-0.115691	-0.009848	0.086967	-0.058037	0.106608	0.338849
lid_open_pct	0.037059	0.401072	-0.059600	0.526093	0.675799	-0.141007	-0.112320	-0.261067
production_draw_rate	0.020491	-0.285002	0.612715	0.152717	0.323104	0.571380	0.257429	0.149878

Table 6: Cargas de los componentes principales (PCA)

El PC1 el componente más importante, explica la mayor parte de la varianza total del sistema. Las variables predominantes acá son: sensor_temp_main y sensor_temp_backup las cuales tienen loadings negativos grandes -0.42 , mientras que heater_power_pct, electrical_current y energy_consumption_kwh tienen loadings positivos grandes, alrededor de 0.45 . Este componente representa el balance energético del horno, es la relación entre la energía que se inyecta al sistema y la temperatura que realmente se obtiene. La temperatura aparecen con signo negativo, porque en este componente la potencia y la temperatura se mueven en direcciones opuestas. Esto no significa que físicamente más potencia siempre implique menor temperatura; lo que significa es que el sistema suele aumentar potencia precisamente cuando detecta una caída térmica. Por lo tanto, PC1 captura el error térmico compensado por el sistema de control. Cuando PC1 es alto, probablemente el horno está demandando mucha energía para sostener el setpoint. Cuando esta bajo, el sistemas está térmicamente más relajado.

En el PC2, se revela una dinámica distinta. Los loadings más grandes corresponden a setpoint (0.565), electrical_voltage (0.500), lid_open_pct (0.401) y aluminum_level_pct (-0.378). Este componente está relacionado con condiciones operativas exógenas al controlador térmico principal. La combinación de variables sugiere que las condiciones eléctricas de alimentación afectan ciertos estados del horno. Además, cuando la tapa se abre con frecuencia, se generan pérdidas convectivas muy fuertes. Cuando el nivel de aluminio cambia, también cambia la inercia térmica del sistema. Un baño de aluminio más lleno almacena más energía térmica; uno más vacío se enfría más rápido. Este componente describe que perturbaciones está recibiendo.

6.1 Partición de datos

Para el entrenamiento y validación de la red neuronal, el conjunto de datos de 14 días se dividió en tres secciones (70% | 15% | 15%). Al ser un modelo basado en una serie de tiempo, la partición se debe hacer estrictamente temporal sin seleccionar al azar los conjuntos de datos.

- Entrenamiento (Train): Del 1 al 10 de mayo (70% inicial).
- Validación (Val): Del 10 al 12 de mayo (15% intermedio).
- Prueba (Test): Del 12 al 14 de mayo (15% final).

El escalado de las variables (StandardScalar) se calibra exclusivamente para el conjunto de entrenamiento, esto nos asegura que el resto de los datos no revelen información estadística del conjunto de prueba, asegurando una predicción evitando el sesgo.

6.2 Requisitos que impone el EDA al modelo

- Inercia térmica: El EDA demostró que el horno tiene una memoria térmica con una duración mayor a 12 horas, lo que afecta el desempeño presente y futuro del horno. Es por eso que no se puede hacer una red neuronal que evalúe de instante a instante, la red neuronal recurrente (LSTM) con la capacidad de procesar datos evaluados con un historial.
- Reducción de Dimensionalidad: El análisis de componentes principales (PCA) demostró que más del 95% de la información se puede representar con 8 componentes. Con esta aproximación justificamos configurar el espacio latente del Autoencoder en 8 dimensiones.
- Detección de Perturbaciones: Observamos que con eventos como la extracción de aluminio o apertura del horno propician las caídas de temperatura. La estructura de Autoencoder tiene el objetivo de detectar los eventos en tiempo real a través de un error de reconstrucción como score de perturbación.
- Compatibilidad: Para ajustar el enfoque de datos contra un modelo físico en Simulink, necesitamos que el modelo genere una salida similar a un sistema de espacio de estados con matrices A, B, C y D. Para esto incluimos una capa final DMDC (Dynamic Mode Decomposition with control) al espacio latente, lo que traduce el aprendizaje de la red neuronal a un modelo de estado lineal comparable con el modelo teórico de control.

6.3 Alternativas evaluadas y criterios de descarte

En el diseño de estrategia de datos, se evaluaron distintas alternativas previo a el modelo final, el proceso de selección se basó en las limitantes físicas del horno y se fueron descartando las opciones:

- Análisis de componentes principales: El modelo necesita del análisis de la inercia térmica, lo que involucra memoria. PCA es excelente para reducir la dimensionalidad y captar la imagen más valiosa de los datos, pero carece de análisis de memoria.
- Redes Neuronales Densas (MLP) y Regresión Estática: Al no tener memoria, no son compatibles con la naturaleza del sistema, incapaces de incluir la inercia térmica en el modelaje.
- LSTM como predictor puro: La red LSTM por sí sola es capaz de predecir la temperatura a futuro, sin embargo, no permite obtener un modelo con polos o funciones de transferencia, lo que imposibilita la comparación con un sistema de control de espacio de estado.
- Modelos con arquitecturas grandes: El principal elemento es la cantidad de datos, y es que con 20,160 muestras no son suficientes para entrenar modelos grandes, ya que es propenso a sobreajuste.

Dicho esto, podemos concluir que el modelo más adecuado es utilizar Autoencoder LSTM seguido de la linealización DMDC para hacer la conexión directa red neuronal a control moderno.

6.4 Decisiones de diseño concretas

Una vez establecidos los requerimientos a partir del EDA, la arquitectura y alimentación del modelo se configuraron bajo los siguientes parámetros:

- Resampleo: Los registros de temperatura están determinados por minuto, decidimos utilizar muestras de cada 5 minutos para asegurarnos de capturar cambios reales y evitar ruido por tantas muestras(minutos).
- Longitud de la Ventana Histórica ($W = 1$ hora): El modelo evalúa bloque históricos de 1 hora equivalentes a 12 secuencias de 5 minutos. Consideramos este intervalo de tiempo ideal para capturar de inicio a fin la evolución de las perturbaciones sin tener que reducir el dataset de manera excesiva tomando en cuenta los 10 días de datos.
- Espacio Latente ($z = 8$): Basado en la comprensión de dimensionalidad derivado del resultado del PCA, el Autoencoder se configuró con 8 variables latentes.
- Definición de entrada: En el modelo de espacio de estados, debemos definir un vector de entradas $u(t)$, tomando en cuenta el porcentaje del calentador, estado de la tapa, rito de extracción, y la temperatura ambiente. Estas variables servirán como las perturbaciones, mientras que las demás variables representan el estado interno del horno(x), así permitiendo una aproximación matricial(A, B, C, D) del control moderno.

7 Implementación del Modelo de Deep Learning

El proceso de diseño comienza desde la limpieza y procesamiento de los datos, que incluye la identificación de picos y resumir los registros de cada minuto a cada 5. Posteriormente, realizamos ventanas temporales (W) con una longitud de 12 ($12 \times 5 = 60$ minutos, es decir, una hora) como contexto histórico. Es así como generamos una matriz de 12×11 (12 pasos de tiempo y 11 variables estandarizadas). El núcleo del modelo de Deep Learning como ya lo hemos mencionado previamente es el LSTM Autoencoder, que sigue el proceso de encode y decode. El proceso de encode es una capa de LSTM que procesa la secuencia temporal de las 11 variables, concentrándose en un estado oculto de 32 dimensiones y sus dependencias históricas. Posteriormente, una transformación lineal comprime este último estado hacia un cuello de botella, generando nuestro vector en el espacio latente (z) de 8 dimensiones. Para el proceso de reconstrucción, el flujo se invierte, se utiliza una proyección lineal que amplifica el espacio latente transformándolo de regreso a las 32 dimensiones originales, sirviendo como estado inicial para una segunda red LSTM. Finalmente, la salida de este decodificador pasa por una capa de proyección final (head), la cual reconstruye las secuencias temporales devolviéndolas a la dimensionalidad original de 11 variables físicas.

7.1 Entrenamiento

El entrenamiento del modelo se llevó a cabo mediante un ciclo que prioriza la estabilidad del gradiente y la robustez ante la no-linealidad del sistema.

- Esquema de optimización: Se selecciona el optimizador Adam ya que ajusta dinámicamente las tasas de actualización en cada parámetro. La tasa de aprendizaje base tiene un valor de 1×10^{-3} con el fin realizar pasos lentos con una seguridad alta.
- Procesamiento por lotes: El conjunto de entrenamiento (2,811 ventanas) se evalúan por lotes de 128 tensores en lugar de evaluar cada uno por iteración, lo cual permite que el cálculo del gradiente sea más ligero y actúe como un regularizador al introducir ruido durante la actualización de los pesos.
- Épocas: Se utilizaron un total de 15 épocas monitoreadas con las curvas de error para verificar que la pérdida de entrenamiento y la de validación convergen de manera conjunta hacia un mínimo.
- Función de Pérdida: Utilizamos el error absoluto medio(MAE) en lugar de el error cuadrático medio(MSE), debido a que el horno presenta perturbaciones transitorias muy fuertes, utilizar el error cuadrático causaría gradientes explosivos que desestabilizan los pesos de la red. Utilizamos la norma L1 para actualizar el gradiente y que permanezca constante y lineal frente a outliers, forzando al modelo a aprender la inercia térmica del sistema y ser tolerante al ruido industrial.

7.2 Resultados del autoencoder

Tras finalizar el proceso de optimización, se evaluó la capacidad de reconstrucción del modelo utilizando el conjunto de prueba aislado. El análisis del Error Cuadrático Medio (MSE) sobre este conjunto arrojó una media de 0.3768 y una mediana de apenas 0.0264. Esto significa que el Autoencoder logra reconstruir la operación del horno de muy cercana a su comportamiento real, pero presenta picos de error agudos y en ventanas de

tiempo muy específicas. Este comportamiento otorga una ventaja operativa crítica ya que el modelo funciona como un detector de perturbaciones. Al analizar las ventanas temporales con mayor tasa de error, confirmamos que la irregularidad se concentra en las variables asociadas a perturbaciones externas, como la apertura de la compuerta y la tasa de extracción de aluminio. Estableciendo un umbral estadístico sobre este error de reconstrucción, el sistema es capaz de fungir como un supervisor automatizado que alerta sobre eventos atípicos severos en la planta.

7.3 Resultados del modelo de espacio de estados latente

A partir de los estados latentes generados por el LSTM Autoencoder, se ajustó un modelo DMDC de la forma:

$$\begin{aligned} z_{k+1} &= Az_k + Bu_k \\ y_k &= Cz_k + Du_k \end{aligned}$$

con un tiempo de muestreo de:

$$\Delta t = 5 \text{ min}$$

donde $z_k \in R^8$ representa el estado latente del horno, $u_k \in \mathbb{R}^4$ representa las entradas operativas del sistema y y_k corresponde a la temperatura principal del horno. Las entradas consideradas fueron:

$$u_k = \begin{bmatrix} \text{heater_power_pct} \\ \text{lid_open_pct} \\ \text{production_draw_rate} \\ \text{ambient_temp} \end{bmatrix}$$

Las matrices obtenidas para el modelo latente fueron:

$$A = \begin{bmatrix} 0.6668 & 0.0960 & 0.0275 & -0.1910 & 0.1482 & 0.0070 & 0.1557 & -0.0564 \\ 0.0341 & 0.7488 & 0.2843 & 0.0924 & 0.0218 & -0.0173 & 0.0028 & 0.0446 \\ -0.0022 & 0.2943 & 0.4661 & -0.1042 & 0.1035 & -0.0157 & -0.0999 & 0.0886 \\ -0.2086 & 0.1037 & -0.1036 & 0.8351 & 0.1044 & -0.0006 & 0.0734 & -0.0403 \\ 0.0939 & 0.0399 & 0.1067 & 0.0748 & 0.6552 & 0.1646 & -0.0194 & -0.1730 \\ -0.0013 & -0.0524 & -0.0197 & -0.0334 & 0.1607 & 0.7708 & 0.0245 & 0.0542 \\ 0.1543 & -0.0185 & -0.1064 & 0.0745 & -0.0232 & 0.0046 & 0.8523 & 0.1154 \\ -0.0158 & 0.0427 & 0.0937 & -0.0120 & -0.1662 & 0.0354 & 0.0914 & 0.7893 \end{bmatrix}$$

$$B = \begin{bmatrix} -0.0550 & 0.0047 & -0.0043 & -0.0652 \\ -0.0024 & 0.0007 & -0.0018 & 0.0022 \\ -0.0079 & -0.0020 & 0.0071 & 0.0689 \\ -0.0444 & 0.0002 & -0.0055 & -0.0139 \\ -0.0206 & -0.0047 & -0.0051 & -0.0199 \\ 0.0143 & 0.0000 & 0.0014 & 0.0380 \\ 0.0211 & 0.0017 & 0.0024 & 0.0389 \\ 0.0122 & 0.0020 & -0.0021 & 0.0194 \end{bmatrix}$$

$$C = [-7.0329 \quad -2.9767 \quad -10.4962 \quad -23.8033 \quad 32.4456 \quad 52.6846 \quad -22.0591 \quad -4.5627]$$

$$D = \begin{bmatrix} -6.8731 & 2.1401 & -1.2179 & 20.4348 \end{bmatrix}$$

Con estas matrices, el modelo obtenido describe la evolución de los 8 estados latentes del horno y su relación con la temperatura principal. La matriz A representa la dinámica interna del sistema en el espacio latente, la matriz B describe el efecto de las entradas operativas sobre dichos estados, la matriz C transforma los estados latentes en temperatura y la matriz D representa el efecto directo de las entradas sobre la salida.

8 Comparación entre el Modelo de Control y el Modelo de Deep Learning

El modelo de control clásico y el modelo basado en Deep Learning representan dos formas distintas de describir la dinámica del horno de sostenimiento. El modelo de control parte de una representación física simplificada del proceso térmico, mientras que el modelo de Deep Learning parte directamente de los datos operativos del horno.

En el modelo de control, el horno se representó mediante una función de transferencia continua asociada a una dinámica térmica lenta, con ganancia, retardo e inercia. Posteriormente, dicha función se convirtió a espacio de estados para poder aplicar técnicas de control moderno. Este enfoque permite obtener una representación de la forma:

$$\begin{aligned}\dot{x}(t) &= Ax(t) + Bu(t) \\ y(t) &= Cx(t) + Du(t)\end{aligned}$$

donde $x(t)$ representa los estados del modelo físico, $u(t)$ es la entrada de control asociada a la potencia suministrada al horno y $y(t)$ corresponde a la temperatura de salida. Esta representación es útil porque permite analizar estabilidad, polos, respuesta temporal y diseño de controladores.

La Figura 10 muestra la respuesta del modelo de control ante una referencia de $700^{\circ}C$. Se observa que la temperatura converge suavemente al valor objetivo, con un comportamiento estable y sin sobreimpulso significativo. Esto es coherente con la dinámica esperada de un horno, ya que la inercia térmica provoca que la respuesta sea lenta y gradual.




Figure 10: Respuesta del modelo de control ante una referencia de 700°C .

Por otro lado, el modelo de Deep Learning utilizó un LSTM Autoencoder para procesar ventanas temporales multivariables del horno. Cada ventana contenía 12 pasos de tiempo, equivalentes a una hora de operación, y 11 variables del proceso. El encoder de la red comprimió esta información en un vector latente de 8 dimensiones:

$$X_k \in \mathbb{R}^{12 \times 11} \longrightarrow z_k \in \mathbb{R}^8$$

Este vector latente z_k se interpretó como un nuevo estado comprimido del horno. Posteriormente, se aplicó DMDC sobre estos estados latentes para obtener un modelo dinámico lineal en espacio de estados discreto:

$$\begin{aligned} z_{k+1} &= Az_k + Bu_k \\ y_k &= Cz_k + Du_k \end{aligned}$$

donde z_k representa los 8 estados latentes aprendidos por el Autoencoder, u_k corresponde a las entradas operativas del sistema y y_k representa la temperatura principal del horno. En este caso, las entradas consideradas fueron:

$$u_k = \begin{bmatrix} \text{heater_power_pct} \\ \text{lid_open_pct} \\ \text{production_draw_rate} \\ \text{ambient_temp} \end{bmatrix}$$

Por lo tanto, el modelo basado en Deep Learning no se queda únicamente como una red neuronal, sino que se transforma en un modelo compatible con control moderno al generar matrices A , B , C y D . En este caso, como el espacio latente tiene 8 dimensiones y se consideran 4 entradas, las dimensiones del modelo son:

$$A \in \mathbb{R}^{8 \times 8}, \quad B \in \mathbb{R}^{8 \times 4}, \quad C \in \mathbb{R}^{1 \times 8}, \quad D \in \mathbb{R}^{1 \times 4}$$

La Figura 11 muestra la comparación entre la temperatura real del horno y la predicción generada por el modelo de espacio de estados latente. La curva azul corresponde a la temperatura real medida por el sensor principal, mientras que la curva roja punteada corresponde al modelo obtenido mediante LSTM Autoencoder y DMDC. Se observa que el modelo latente logra seguir la tendencia general de la temperatura, especialmente durante cambios de régimen térmico. Sin embargo, también presenta oscilaciones y desviaciones locales, debido a que el modelo fue aprendido directamente desde datos reales y puede capturar ruido o correlaciones operativas.




Figure 11: Comparación entre la temperatura real y el modelo de espacio de estados latente obtenido mediante LSTM Autoencoder y DMDC.

A partir del modelo de espacio de estados latente se obtuvo una función de transferencia discreta desde la entrada *heater_power_pct* hacia la temperatura principal del horno. La función de transferencia de orden 8 obtenida fue:

$$G(z) = \frac{-0.5077z^8 + 3.018z^7 - 7.687z^6 + 10.92z^5 - 9.422z^4 + 5.028z^3 - 1.61z^2 + 0.2807z - 0.02021}{z^8 - 5.784z^7 + 14.28z^6 - 19.57z^5 + 16.2z^4 - 8.242z^3 + 2.493z^2 - 0.4052z + 0.02659}$$

con un tiempo de muestreo de:

$$\Delta t = 5 \text{ min}$$

Este modelo de orden 8 proviene directamente de los 8 estados latentes generados por el Autoencoder. Sin embargo, para facilitar la comparación con el modelo clásico de control, se realizó una reducción de orden, conservando los modos dominantes del sistema. La función de transferencia reducida de segundo orden fue:

$$G_2(z) = \frac{-0.5077z^2 + 0.9878z - 0.481}{z^2 - 1.977z + 0.9773}$$

Los polos de esta función reducida fueron:

$$p_{1,2} = 0.9885 \pm 0.0083j$$

Estos polos están cerca de 1 en el plano discreto, lo que indica una dinámica lenta y persistente. Esto es consistente con la memoria térmica del horno, ya que la temperatura no cambia de forma instantánea, sino que conserva el efecto de estados anteriores durante largos periodos.

También se obtuvo una aproximación continua de segundo orden:

$$G(s) = \frac{-0.4667s + 3.11 \times 10^{-3}}{s^2 + 7.33 \times 10^{-3}s + 4.44 \times 10^{-6}}$$

Esta función permite comparar el modelo latente con el enfoque clásico de control en el dominio continuo. Aunque el modelo de Deep Learning fue obtenido desde datos y no desde principios físicos directos, su reducción de orden permite identificar una dinámica dominante comparable con la dinámica térmica esperada del horno.

La Figura 12 muestra el diagrama de Bode de magnitud para la relación entre la potencia del calentador y la temperatura. Se comparan tres modelos: la función de transferencia latente de orden 8, la función reducida de orden 2 y el modelo continuo de segundo orden. Se observa que el modelo clásico presenta una caída más marcada en altas frecuencias, lo cual es coherente con un sistema térmico de alta inercia que atenúa cambios rápidos. En cambio, los modelos latentes no caen con la misma intensidad, lo que indica que conservan cierta sensibilidad a variaciones rápidas aprendidas desde los datos.




Figure 12: Comparación en frecuencia entre la función de transferencia latente, la función reducida y el modelo continuo de segundo orden.

En términos de comparación, el modelo de control clásico es más interpretable y adecuado para el diseño directo de controladores, ya que sus estados, polos y respuesta temporal tienen una relación clara con la dinámica física del horno. Por su parte, el modelo de Deep Learning permite aprovechar los datos reales del proceso y construir un espacio de estados latente que captura relaciones multivariantes entre temperatura, potencia, apertura de tapa, producción y temperatura ambiente.

La diferencia principal es que el modelo clásico representa una dinámica ideal y suave del horno, mientras que el modelo latente representa una dinámica aprendida desde datos reales. Por esta razón, el modelo de Deep Learning puede seguir tendencias operativas

reales, pero también puede presentar oscilaciones o efectos asociados al ruido y a correlaciones no causales. En conjunto, ambos enfoques son complementarios: el modelo clásico es más adecuado para diseño y validación de control, mientras que el modelo basado en Deep Learning y DMDC es útil para análisis operativo, identificación de patrones y construcción de modelos dinámicos a partir de datos reales.

9 Discusión de Resultados

Los resultados obtenidos muestran que el horno de sostenimiento tiene una dinámica térmica lenta y con bastante memoria. Esto era esperado, ya que el aluminio fundido y el material refractario almacenan una gran cantidad de energía, por lo que la temperatura no cambia de forma inmediata cuando se modifica la potencia del calentador. Por esta razón, el sistema se analizó desde dos enfoques: un modelo físico de control moderno y un modelo basado en datos mediante Deep Learning.

En el modelo de control clásico, el horno se representó primero mediante una función de transferencia con ganancia, retardo e inercia térmica. Los valores utilizados, $K_p = 700$, $\tau = 3600$ s y $\theta = 300$ s, permitieron describir una respuesta lenta y progresiva, coherente con el comportamiento esperado de un horno industrial. La aproximación de Padé permitió incluir el retardo dentro de una función racional y después convertir el sistema a espacio de estados. Esto hizo posible diseñar un controlador por realimentación de estados y un observador.

El controlador se diseñó con amortiguamiento crítico, $\zeta = 1$, y polos deseados en $s = -0.000667$. Al estar cerca del origen, estos polos generan una respuesta lenta, pero estable, lo cual es adecuado para este tipo de proceso térmico. En la simulación sin perturbaciones, el sistema logró seguir la referencia de $700^\circ C$ de manera suave, sin sobreimpulso significativo y con un error estacionario muy bajo. Esto indica que, bajo el modelo físico ideal, el controlador cumple correctamente su objetivo.

La ganancia K_c permitió modificar la dinámica del sistema en lazo cerrado, mientras que la ganancia N ayudó a que la salida alcanzara correctamente la referencia. Además, el observador de estados permitió estimar variables internas del sistema que no necesariamente podrían medirse directamente en un horno real. Los polos del observador se colocaron en $s = -1$, mucho más rápidos que los polos del controlador, para que el error de estimación desapareciera rápidamente. Por esta razón, el observador puede entenderse como un sensor virtual que reconstruye los estados internos del horno.

Sin embargo, al analizar los datos reales se observó que el horno tiene un comportamiento más complejo que el modelo físico simplificado. El conjunto de datos contiene 20,160 observaciones tomadas durante 14 días y 11 variables del proceso. Una de las observaciones más importantes fue que la temperatura real se mantiene frecuentemente por debajo del setpoint de $700^\circ C$, incluso cuando el calentador trabaja cerca de su máxima capacidad. Al considerar los momentos con $T_{real} > 650^\circ C$ y $heater_power_pct \geq 95\%$, se obtuvo un error promedio de aproximadamente $40.93^\circ C$. Esto sugiere que el horno puede estar operando cerca de su límite térmico durante una parte importante del tiempo.

Este resultado no significa necesariamente que el controlador esté fallando. De hecho, la correlación entre el error de temperatura y la potencia del calentador muestra que el controlador sí responde cuando la temperatura se aleja de la referencia. Es decir, cuando

aumenta el error, también aumenta la potencia solicitada. Por lo tanto, el error restante parece estar más relacionado con limitaciones físicas del proceso, pérdidas de calor o perturbaciones operativas, como aperturas de tapa o extracción de aluminio.

Otro resultado importante del EDA fue la memoria térmica del horno. La autocorrelación mostró que la temperatura mantiene dependencia con valores pasados durante un periodo largo. Esto significa que el comportamiento actual del horno no depende únicamente de la potencia aplicada en el momento, sino también de lo que ocurrió previamente. Este hallazgo justificó el uso de una red LSTM, ya que este tipo de arquitectura puede trabajar con secuencias y conservar información temporal.

Con base en lo anterior, se utilizó un LSTM Autoencoder para comprimir ventanas temporales de una hora, formadas por 12 pasos de tiempo y 11 variables del proceso. El modelo redujo cada ventana a un espacio latente de 8 dimensiones. Esta decisión fue consistente con el análisis PCA, donde se observó que 8 componentes eran suficientes para conservar más del 95% de la información del sistema. De esta manera, el Autoencoder permitió resumir el comportamiento multivariable del horno en un conjunto reducido de estados latentes.

Después, se aplicó DMDC sobre estos estados latentes para obtener un modelo dinámico lineal en espacio de estados discreto:

$$\begin{aligned} z_{k+1} &= Az_k + Bu_k \\ y_k &= Cz_k + Du_k \end{aligned}$$

Este paso fue importante porque permitió conectar el modelo de Deep Learning con una estructura compatible con control moderno. Es decir, la red neuronal no se utilizó solo como una caja negra, sino como una forma de generar estados latentes que después pudieron modelarse mediante matrices A , B , C y D .

Al comparar la temperatura real con la predicción del modelo latente, se observó que el enfoque LSTM Autoencoder + DMDC logra seguir la tendencia general del horno, especialmente durante cambios importantes de temperatura. Sin embargo, también presenta oscilaciones y desviaciones locales. Esto es razonable porque el modelo fue aprendido desde datos reales, los cuales incluyen ruido, perturbaciones y correlaciones operativas. Por ello, el modelo latente captura parte importante de la dinámica real, aunque no tiene la misma suavidad ni la misma interpretación física directa que el modelo clásico.

También se compararon los modelos mediante funciones de transferencia. El modelo clásico mostró una caída más clara en altas frecuencias, lo cual es consistente con un horno real: el sistema responde a cambios lentos, pero atenúa cambios rápidos debido a su inercia térmica. En cambio, las funciones de transferencia obtenidas del modelo latente no caen con la misma intensidad, lo que sugiere que el modelo basado en datos también aprendió variaciones rápidas, ruido o efectos operativos presentes en el proceso real.

En general, los resultados muestran que ambos enfoques son útiles, pero para propósitos distintos. El modelo de control clásico es más interpretable y adecuado para diseñar controladores, analizar estabilidad y justificar el comportamiento esperado del horno. Por otro lado, el modelo basado en Deep Learning permite aprovechar los datos reales del proceso, capturar relaciones multivariables y detectar patrones que el modelo físico simplificado no representa completamente.

Por lo tanto, el modelo físico y el modelo de Deep Learning no se sustituyen entre sí, sino que se complementan. El primero proporciona una base estable y clara para el control, mientras que el segundo aporta una visión basada en datos reales para entender mejor la operación del horno, identificar perturbaciones y construir modelos dinámicos más cercanos al comportamiento observado en planta.

10 Conclusiones

El horno de sostenimiento presenta una dinámica térmica lenta, con alta inercia y una memoria prolongada, por lo que su temperatura no responde de manera inmediata ante cambios en la potencia aplicada. El modelo de control moderno permitió representar esta dinámica de forma clara mediante espacio de estados, diseñar un controlador estable y agregar un observador capaz de estimar los estados internos del sistema. Las simulaciones nos mostraron que, bajo el modelo físico propuesto; el controlador logra seguir la referencia de 700°C de manera suave, sin sobreimpulso significativo y con un error estacionario bajo. Esto confirma que la estrategia de realimentación de estados es adecuada para un proceso térmico donde se busca estabilidad más que rapidez.

Por otro lado, el análisis de datos nos demostró que el horno opera frecuentemente por debajo del setpoint y que el calentador trabaja cerca de su máxima capacidad durante una gran parte del tiempo. Esto llega a sugerir, que el problema no se debe únicamente al controlador, ya que este sí responde aumentando la potencia cuando crece el error; sino también a posibles limitaciones físicas, pérdidas térmicas o perturbaciones operativas. El uso del LSTM Autoencoder permitió resumir el comportamiento multivariable del horno en estados latentes, mientras que DMDC nos permitió transformar esos estados en un modelo compatible con espacio de estados. A pesar de que este modelo basado en datos no sustituye al modelo físico, sí aporta una manera robusta de capturar patrones reales del proceso y analizar dinámicas que el modelo clásico no puede representar completamente.

Por último, ambos enfoques se complementan. El modelo de control clásico ofrece una base estable e interpretable para el diseño del controlador, mientras que, el modelo de Deep Learning permite aprovechar los datos reales para monitoreo, análisis de perturbaciones y futura mejora del sistema. Es debido a ello que, la combinación de control moderno e inteligencia artificial representa una alternativa prometedora para mejorar la operación térmica de hornos industriales.

References

- [1] Scribd. (n.d.). *A356.0 Aluminum Alloy Specifications / PDF / Strength Of Materials / Yield (Engineering)*. Recuperado el 12 de junio de 2026, de <https://www.scribd.com/document/213781675/A356-0-Alloy-Detail>
- [2] IJERT. (n.d.). *Identification and Control of Micro Porosity for Al-Alloy Wheel Castings*. Recuperado el 12 de junio de 2026, de <https://www.ijert.org/identification-and-control-of-micro-porosity-for-al-alloy-wheel-castings>
- [3] GeeksforGeeks. (n.d.). *Introduction To Adam Optimizer*. Recuperado de <https://www.geeksforgeeks.org/deep-learning/adam-optimizer/>

- [4] Wikipedia. (2025). *Liquidus and solidus*. Recuperado de https://en.wikipedia.org/w/index.php?title=Liquidus_and_solidus&oldid=1314108098
- [5] Ou, J., Wei, C., Cockcroft, S., Maijer, D., Zhu, L., A, L., Li, C., & Zhu, Z. (2020). Advanced Process Simulation of Low Pressure Die Cast A356 Aluminum Automotive Wheels—Part I, Process Characterization. *Metals*, 10(5), 563. <https://doi.org/10.3390/met10050563>
- [6] IBM. (n.d.). *¿Qué es un autocodificador?*. Recuperado el 12 de junio de 2026, de <https://www.ibm.com/mx-es/think/topics/autoencoder>
- [7] Codificando Bits. (2019, 20 de julio). *¿Qué son las Redes LSTM?*. Recuperado de <https://codificandobits.com/blog/redes-lstm/>
- [8] Kalyani Furnaces India Pvt. Ltd. (n.d.). *Why LPDC Aluminium Holding Furnaces Are Important for Precision Casting Industries in Maharashtra*. Recuperado el 12 de junio de 2026, de <https://www.kalyanifurnaces.in/latest-update/why-lpdc-aluminium-holding-furnaces-are-important-for-precision-casting-industries> 197
- [9] Zhang, B., Cockcroft, S. L., Maijer, D. M., Zhu, J. D., & Phillion, A. B. (2005). Casting defects in low-pressure die-cast aluminum alloy wheels. *JOM*, 57(11), 36–43. <https://doi.org/10.1007/s11837-005-0025-1>